

Esper – podstawy – zadanie własne

ScoreEvents

1. Pobierz wersję początkową naszego projektu

```
git clone https://github.com/BigDataStreamProcessing/esper-ScoreEvents.git
```

2. Przejdź do katalogu projektu, a następnie usuń powiązanie z projektem zewnętrznym

```
cd esper-ScoreEvents
git remote rm origin
```

3. Otwórz katalog esper-ScoreEvents w *IntelliJ IDEA*.
4. Zapoznaj się z jego zawartością.
 - a. Odnajdź fragment, który zawiera polecenia EPL dostarczane do kompilacji.

```
// Compile the EPL statement
EPCompiler compiler = EPCompilerProvider.getCompiler();
EPCompiled epCompiled;
try {
    epCompiled = compiler.compile(s: """
        @public @buseventtype create json schema ScoreEvent(house string, character string, score int, ets string, its string);
        @name('answer') SELECT house, score, character, ets, its
        from ScoreEvent#ext_timed(java.sql.Timestamp.valueOf(its).getTime(), 3 sec)""", compilerArgs);
}
catch (EPCompileException ex) {
    // handle exception here
    throw new RuntimeException(ex);
}
return epCompiled;
```

- i. Zapoznaj się ze schematem, który został zarejestrowany.
 - ii. Zapoznaj się z poleceniem, którego wyniki będą pobierane jako rezultat przetwarzania
- b. Odnajdź fragment, który dostarcza efekt kompilacji do obiektu `EPRuntime`.

```
EPCompiled epCompiled = getEPCompiled(config);

// Connect to the EPRuntime server and deploy the statement
EPRuntime runtime = EPRuntimeProvider.getRuntime(uri: "http://localhost:port", config);
EPDeployment deployment;
try {
    deployment = runtime.getDeploymentService().deploy(epCompiled);
}
catch (EPDeployException ex) {
    // handle exception here
    throw new RuntimeException(ex);
}
```

- c. W której linii tworzony jest obiekt `EPStatement` i z którym zapytaniem jest powiązany?
Na podstawie czego następuje to powiązanie?

- d. Odnajdź fragment, który przypisuje obiekt Listenera do zapytania

```
// Add a listener to the statement to handle incoming events
resultStatement.addListener( (newData, oldData, stmt, runtime) -> {
    for (EventBean eventBean : newData) {
        System.out.printf("R: %s\n", eventBean.getUnderlying());
    }
});
```

- e. Odnajdź fragment, który wykorzystując bibliotekę *DataFaker* (<https://www.datafaker.net>) zasila nasz silnik przetwarzania strumieni danych

```
Faker faker = new Faker();

long startTime = System.currentTimeMillis();
while (System.currentTimeMillis() < startTime + (1000L * howLongInSec)) {
    waitToEpoch();
    for (int i = 0; i < noOfRecordsPerSec; i++) {
        String house = faker.harryPotter().house();
        Timestamp eTimestamp = faker.date().past(atMost: 30, TimeUnit.SECONDS);
        eTimestamp.setNanos(0);
        Timestamp iTimestamp = Timestamp.valueOf(LocalDateTime.now().withNano(nanoOfSecond: 0));

        Schema<Object, ?> schema = Schema.of(
            field(name: "house", () -> house),
            field(name: "character", () -> faker.harryPotter().character()),
            field(name: "score", () -> String.valueOf(faker.number().randomDigitNotZero())),
            field(name: "ets", eTimestamp::toString),
            field(name: "its", iTimestamp::toString)
        );

        JsonTransformer<Object> transformer = JsonTransformer.builder().build();
        String record = transformer.generate(schema, limit: 1);
        runtime.getEventService().sendEventJson(record, s1: "ScoreEvent");
    }
}
```

- f. W jaki sposób wykorzystywane są parametry programu `noOfRecordsPerSec` oraz `howLongInSec`?
- g. Do czego służy funkcja `waitToEpoch`?

5. Uruchom program

```
R: {score=3, its=2024-02-21 09:18:07.0, character=Nagini, house=Hufflepuff, ets=2024-02-21 09:17:54.0}
R: {score=1, its=2024-02-21 09:18:07.0, character=Antioch Peverell, house=Gryffindor, ets=2024-02-21 09:18:02.0}
R: {score=9, its=2024-02-21 09:18:08.0, character=Vincent Crabbe, Sr., house=Wampus, ets=2024-02-21 09:17:55.0}
R: {score=9, its=2024-02-21 09:18:08.0, character=Aragog, house=Gryffindor, ets=2024-02-21 09:17:49.0}
R: {score=3, its=2024-02-21 09:18:09.0, character=Goyle Sr., house=Gryffindor, ets=2024-02-21 09:18:07.0}
R: {score=9, its=2024-02-21 09:18:09.0, character=James Potter, house=Pukwudgie, ets=2024-02-21 09:17:49.0}
R: {score=8, its=2024-02-21 09:18:10.0, character=Alecto Carrow, house=Horned Serpent, ets=2024-02-21 09:17:44.0}
```

6. Zmień zapytanie na takie, które będzie wydobywało te wyniki, które przekraczają średni rezultat uzyskany dla danego domu w ciągu ostatnich 10 sekund. Skoryguj parametry tak, aby liczba rekordów generowanych w sekundzie była równa 20, a czas generowania danych był równy 30 sekund. Uruchom tak skorygowany program.

```
R: {score=8, character=Ronan, house=Wampus, avgscore=6.666666666666667}
R: {score=6, character=Madam Rosmerta, house=Thunderbird, avgscore=5.333333333333333}
R: {score=9, character=Horace Slughorn, house=Thunderbird, avgscore=6.25}
R: {score=8, character=Seamus Finnigan, house=Ravenclaw, avgscore=6.333333333333333}
```

...

```
R: {score=6, character=Mr. Roberts, house=Pukwudgie, avgscore=4.928571428571429}
R: {score=9, character=Luna Lovegood, house=Hufflepuff, avgscore=5.346153846153846}
R: {score=6, character=Horace Slughorn, house=Ravenclaw, avgscore=4.916666666666667}
R: {score=6, character=Poppy Pomfrey, house=Gryffindor, avgscore=3.84}
```

Twój własny zestaw danych

7. Zapoznaj się z możliwościami biblioteki *DataFaker*
<https://www.datafaker.net/documentation/getting-started/>
<https://www.datafaker.net/documentation/providers/>
8. Opracuj swój własny generator strumienia danych oparty na swoim własnym schemacie zdarzeń. Kilka elementów jest obowiązkowych:
- Znacznik czasowy zdarzeń (inny niż czas systemowy opóźniony w stosunku do czasu systemowego najwyżej o 40 sekund) – *ets (event timestamp)*
 - Znacznik czasu systemowego – *its (internal timestamp)*
 - Atrybut, lub atrybuty, po których można dane grupować (zawierający/e ograniczoną liczbę możliwych wartości (5-10))
 - Atrybut lub atrybuty, których wartości można agregować (wartości numeryczne)
 - Atrybut lub atrybuty dodatkowe, opisujące zdarzenie

DataFaker ma ponad 200 tzw. *providerów* danych. To naprawdę oznacza duży wybór.

Użyj wyobraźni. Niech to nie będzie „kalka” *ScoreEvents*. Zawsze możesz opracować generator strumienia danych swojej własnej rzeczywistości (wykraczającej poza wbudowanych *providerów*) wykorzystując *providerów* ogólnych (generujących wartości będące np. datami, liczbami, czy wartościami z podanego przez Ciebie zbioru). Niech to nie będzie rzeczywistość „magiczna”. Postaraj się opracować generator danych „z naszego świata”. Przykładowo:

- oglądnięcia filmów na platformach VOD
- wykorzystanie współdzielonych pojazdów miejskich
- podróże taksówkami
- przeloty samolotów
- żądania HTTP generowane na portalach przez ich użytkowników
- itp.

Jeśli masz jakieś wątpliwości przedyskutuj swój pomysł z prowadzącym.

Zwróć uwagę, że kurs dotyczy przetwarzania strumieni danych. Twój generator ma być generatorem zdarzeń... nie każda dana jest zdarzeniem. Nie każdy zbiór krotek można traktować jak strumień.